

Wielokryterialna ocena jakości powietrza w mieście włoskim.

Olimpia Dejko

Natalia Bardadyn

Streszczenie

Celem projektu jest analiza jakości powietrza na podstawie danych z czujników chemicznych [1]. Praca skupia się na segmentacji stanów atmosferycznych przy użyciu metod analizy skupień: algorytmu k-średnich oraz hierarchicznej metody Warda.

Proces badawczy objął przygotowanie danych, w tym obsługę brakujących wartości (kodowanych jako -200) oraz wstępną analizę statystyczną (średnia, odchylenie, skośność) i wizualizację za pomocą histogramów i boxplotów. Do analizy wybrano sześć zmiennych, m.in. stężenia CO, NO_x i NO₂, pełniących rolę destymulantów. Kluczowym elementem było wyodrębnienie grup o podobnym poziomie zanieczyszczeń oraz porównanie wyników obu metod w celu oceny jakości uzyskanych skupień. Badanie pozwala zidentyfikować powtarzalne wzorce emisji gazów i ocenić strukturę danych w zależności od parametrów pogodowych.

Słowa kluczowe

analiza skupień, standaryzacja danych, metoda k-średnich, metoda Warda.

Wprowadzenie

Współczesna analiza danych środowiskowych staje się kluczowym narzędziem w walce z narastającym problemem smogu i degradacji jakości powietrza w obszarach zurbanizowanych. Monitorowanie stężeń toksycznych gazów, takich jak tlenek węgla czy tlenki azotu, generuje ogromne zbiory danych, które bez odpowiedniej obróbki statystycznej są trudne do interpretacji. Niniejszy projekt podejmuje temat segmentacji stanów atmosferycznych, wykorzystując do tego celu wielowymiarowy

zbiór danych **Air Quality** pochodzący z włoskiej stacji badawczej, udostępniony w repozytorium **UCI Machine Learning**.

Głównym problemem badawczym jest próba odpowiedzi na pytanie, czy w rejestrowanych pomiarach można wyodrębnić naturalne skupienia odpowiadające różnym profilom zanieczyszczenia (np. godziny szczytu komunikacyjnego vs. godziny nocne). W tym celu zastosowano podejście taksonomiczne oparte na **analizie skupień**. Pozwala ona na pogrupowanie obiektów (dni lub godzin pomiarowych) w taki sposób, aby jednostki wewnątrz jednej grupy były do siebie jak najbardziej podobne, a między grupami – maksymalnie zróżnicowane.

W pracy wykorzystano dwie konkurencyjne metody grupowania: **algorytm k-średnich** oraz hierarchiczną **metodę Warda**. Porównanie tych podejść ma na celu nie tylko segmentację danych, ale również ocenę stabilności i wiarygodności uzyskanych wyników. Całość analizy poprzedzono rygorystycznym przygotowaniem danych, w tym obsługą specyficznych braków pomiarowych oraz normalizacją zmiennych, co jest niezbędnym etapem w procesie eksploracji danych maszynowych.

Przedmiot badania

Przedmiotem badania jest analiza wielowymiarowych sygnałów z czujników chemicznych umieszczonych w urządzeniu typu „elektroniczny nos”, zlokalizowanym na zanieczyszczonym obszarze miejskim we Włoszech. Badanie skupia się na interakcjach między stężeniami gazów (CO, NO_x, NO₂) a zmiennymi warunkami atmosferycznymi (temperatura, wilgotność).

Cel i zakres badania

Celem głównym jest segmentacja stanów jakości powietrza przy użyciu algorytmów analizy skupień, aby wyodrębnić okresy o zbliżonej charakterystyce emisyjnej.

Zakres badania obejmuje:

- Preprocessing danych (czyszczenie i imputacja).
- Analizę statystyczną 6 wybranych zmiennych diagnostycznych.
- Grupowanie obiektów metodą k-średnich oraz metodą Warda.
- Porównanie i ocenę jakości uzyskanych skupień.

Przegląd literatury

W literaturze przedmiotu wskazuje się, że sensory chemiczne często wykazują dryf i wrażliwość na zmienne pogodowe [2].

Opis: Autorzy badali możliwości kalibracji tanich czujników półprzewodnikowych w warunkach polowych. Wykazali, że zmienne takie jak temperatura istotnie modyfikują odczyty stężeń gazów, co uzasadnia włączenie danych meteorologicznych do niniejszej analizy skupień. Autorzy sugerują, że ze względu na nieliniowość sygnałów, kluczowe jest stosowanie metod statystycznych pozwalających na wyodrębnienie powtarzalnych wzorców zanieczyszczeń w warunkach miejskich.

Zmienne wybrane do analizy

Do badania wybrano 6 zmiennych, które pozwalają na kompleksową ocenę stanu atmosfery:

Zmienna	Opis	Uzasadnienie
CO(GT)	Stężenie tlenku węgla	Główny produkt niepełnego spalania paliw.
NMHC(GT)	Stężenie niemetanowych węglowodorów	Wskaźnik emisji przemysłowych i komunikacyjnych.
C6H6(GT)	Stężenie benzenu	Substancja silnie rakotwórcza, marker spalin.
NOx(GT)	Stężenie tlenków azotu	Kluczowy składnik smogu fotochemicznego.
NO2(GT)	Stężenie dwutlenku azotu	Gaz toksyczny, wpływający na drogi oddechowe.
T	Temperatura powietrza	Wpływa na szybkość reakcji chemicznych w atmosferze.

Wstępna analiza danych

Statystyki opisowe

- *CO(GT): średnia 2.35, mediana 2.00, min 0.30, max 8.10, odchylenie standardowe 1.41, skośność dodatnia (1.07).*
- *NMHC(GT): średnia 231.03, mediana 157.00, min 7.00, max 1189.00, odchylenie standardowe 208.46, skośność dodatnia (1.49).*
- *C6H6(GT): średnia 10.77, mediana 9.10, min 0.50, max 39.20, odchylenie standardowe 7.42, skośność dodatnia (0.99).*
- *NOx(GT): średnia 143.50, mediana 128.00, min 12.00, max 478.00, odchylenie standardowe 81.83, skośność dodatnia (0.87).*
- *NO2(GT): średnia 100.26, mediana 99.00, min 19.00, max 196.00, odchylenie standardowe 31.49, rozkład zbliżony do symetrycznego (skośność 0.07).*
- *T: średnia 15.60, mediana 15.00, min 6.30, max 30.00, odchylenie standardowe 4.83, umiarkowana skośność dodatnia (0.63).*

Rozkłady analizowanych zmiennych wykazują asymetrię prawostronną, co oznacza przewagę niskich wartości stężeń oraz sporadyczne występowanie wysokich poziomów zanieczyszczeń. Szczególnie widoczne jest to dla NMHC(GT) oraz CO(GT), co może wskazywać na epizodyczne wzrosty emisji, np. w godzinach szczytu komunikacyjnego.

Braki danych i obserwacje odstające


- **Braki danych:** Braki danych oznaczone jako -200 zostały zastąpione wartościami NaN, a następnie usunięto obserwacje zawierające brakujące dane. Po procesie czyszczenia do dalszej analizy pozostało 827 obserwacji.
- **Obserwacje odstające:** Wykryte za pomocą **wykresów pudełkowych (boxplot)**. Dotyczyły głównie ekstremalnych stężeń NOx w godzinach szczytu. Zdecydowano o ich pozostawieniu, ponieważ niosą kluczową informację o stanach alarmowych jakości powietrza.

Podstawowa wizualizacja

W projekcie wykorzystano:


- **Histogramy:** Ukazały rozkład stężeń gazów, zbliżony do log-normalnego (silna asymetria prawostronna).

Histogramy zmiennych



Rysunek 1. Histogramy wybranych zmiennych opisujących jakość powietrza.

- **Boxploty:** Pozwoliły na wizualne porównanie zakresów zmienności oraz identyfikację outlierów dla każdej z 6 zmiennych.



Rysunek 2. Wykres pudełkowy (boxplot) analizowanych zmiennych.

Na podstawie histogramów stwierdzono, że większość zmiennych posiada rozkład asymetryczny, z długim ogonem po stronie wysokich wartości. Wykresy pudełkowe (boxploty) ujawniły obecność licznych obserwacji odstających, szczególnie dla zmiennych NMHC(GT) oraz NOx(GT), co wskazuje na epizody wysokiego zanieczyszczenia powietrza. Wizualizacje przedstawiono na rysunkach 1 i 2.

Opis metod

W projekcie, zastosowano dwie komplementarne metody analizy skupień, aby zweryfikować spójność grupowań danych o jakości powietrza.

0. Standaryzacja danych

Przed przystąpieniem do analizy skupień dane poddano procesowi standaryzacji. Jest to krok niezbędny, ponieważ algorytmy oparte na odległości są wrażliwe na różnice w skalach i jednostkach zmiennych. Standaryzacja sprowadza wszystkie cechy do postaci o średniej równej 0 i odchyleniu standardowym równym 1, zgodnie ze wzorem:

$$Z = \frac{x - \mu}{\sigma}$$

gdzie:

- z – wartość wystandaryzowana,
- x – pierwotna wartość zmiennej,
- μ – średnia arytmetyczna danej zmiennej,
- σ – odchylenie standardowe danej zmiennej.

Dzięki temu każda z sześciu wybranych zmiennych ma jednakowy wpływ na proces wyodrębniania klastrów

1. Metoda k-średnich

Jej celem jest podział n obserwacji na k rozłącznych skupień, w których każda obserwacja należy do skupienia o najbliższej średniej [3]. Algorytm dąży do zminimalizowania wewnątrzgrupowej sumy kwadratów odległości:

$$J = \sum_{j=1}^k \sum_{i \in S_j} ||x_i - \mu_j||^2$$

gdzie:

- k – liczba skupień,
- S_j – zbiór obserwacji należących do j -tego skupienia,
- μ_j – środek ciężkości (centroid) skupienia S_j .

2. Metoda Warda

Jest to hierarchiczna metoda aglomeracyjna. W odróżnieniu od innych metod wiązania, metoda Warda nie opiera się na odległościach między skupieniami, lecz na analizie wariancji [4]. Kryterium wyboru pary skupień do połączenia jest minimalizacja przyrostu całkowitej wewnątrzgrupowej sumy kwadratów odchyleń (ESS – Error Sum of Squares):

$$ESS = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2$$

gdzie:


- n – liczba obiektów w zbiorze

Metoda ta dąży do tworzenia skupień o zbliżonej liczebności i dużej homogeniczności wewnętrznej.

Rezultaty

Dobór liczby klastrów

W celu określenia optymalnej liczby klastrów zastosowano metodę łokcia (elbow method), opartą na analizie wartości funkcji celu. Wykres wskazał wyraźne załamanie krzywej przy liczbie klastrów $k=3$, co uzasadnia wybór tej liczby skupień do dalszej analizy.



Rysunek 3. Wykres metody łokcia służący do wyboru liczby klastrów.

W wyniku zastosowania algorytmu k-średnich oraz metody Warda uzyskano podział danych na trzy skupienia. Wizualizacja wyników przy użyciu analizy głównych


składowych (PCA) umożliwiła przedstawienie struktury klastrow w przestrzeni dwuwymiarowej.

Metoda k-średnich pozwoliła wyodrębnić trzy wyraźne grupy:


- **Skupienie 1 (Niska emisja):** Charakteryzuje się najniższymi stężeniami wszystkich gazów toksycznych (CO, NO_x, NO₂) oraz stabilną temperaturą.
- **Skupienie 2 (Średnie zanieczyszczenie):** Stan przejściowy, w którym poziomy zanieczyszczeń są podwyższone, ale nie przekraczają norm alarmowych.
- **Skupienie 3 (Wysoka emisja / Szczyt komunikacyjny):** Skupienie o najwyższych wartościach tlenków azotu i benzenu.

Metoda Warda ujawniła bardziej złożoną strukturę danych, identyfikując również stany pośrednie między skrajnymi poziomami zanieczyszczeń.

Zaobserwowane skupienia mogą odpowiadać różnym porom dnia, np. godzinom szczytu komunikacyjnego oraz okresom nocnym o niższym poziomie emisji.



Rysunek 4. Wizualizacja skupień metodą k-średnich (PCA).



Rysunek 5. Wizualizacja skupień metodą Warda (PCA).

Ocena jakości

Jakość uzyskanych skupień oceniono za pomocą współczynnika silhouette. Dla metody k-średnich uzyskano wartość **0.375**, natomiast dla metody Warda **0.354**, co wskazuje na umiarkowaną jakość segmentacji.

W celu dodatkowej oceny jakości uzyskanych skupień zastosowano miarę redukcji wariancji R^2 , która określa, jaka część całkowitej zmienności danych została wyjaśniona przez podział na klastry. Miara ta opiera się na zależności:

$$R^2 = 1 - \frac{WSS}{TSS}$$

Gdzie:

TSS – całkowita suma kwadratów odchyleń,

WSS – suma kwadratów odchyleń wewnątrz klastrów.

Wartości R^2 mieszczą się w przedziale od 0 do 1, a im są bliższe 1, tym lepsza jakość grupowania.

Wyniki:

k-średnich: $R^2 = 0,6763$ (67,63%)

Metoda Warda: $R^2 = 0,6473$ (64,73%)

Uzyskane wartości wskazują na dobrą jakość segmentacji danych, przy czym metoda k-średnich osiągnęła nieco lepsze dopasowanie niż metoda Warda. Wyniki te są spójne z wartościami współczynnika silhouette (0,375 i 0,354), co zwiększa wiarygodność przeprowadzonej analizy.

Porównanie metod

Porównanie wyników obu metod wykazało umiarkowane podobieństwo (ok. 42%), co oznacza, że metody częściowo zgadzają się w przypisaniu obserwacji do klastrów, jednak różnią się w szczegółowej strukturze skupień. Algorytm k-średnich uzyskał nieco lepsze wyniki jakościowe, osiągając wyższe wartości współczynnika silhouette (0,375) oraz miary redukcji wariancji R^2 (67,63%) w porównaniu z metodą Warda (odpowiednio 0,354 i 64,73%).

Podsumowanie

Przeprowadzona analiza skupień pozwoliła na identyfikację trzech charakterystycznych stanów jakości powietrza: niskiego, umiarkowanego oraz wysokiego poziomu zanieczyszczeń. Wyniki uzyskane za pomocą dwóch różnych metod grupowania są do siebie zbliżone, co zwiększa wiarygodność przeprowadzonej analizy.

1. **Ocena metod:** Zastosowanie dwóch algorytmów – niehierarchicznego (k-średnich) oraz hierarchicznego (metoda Warda) – pozwoliło na wielokryterialne spojrzenie na strukturę danych. Mimo różnic w sposobie przypisywania obiektów (zbieżność na poziomie ok. 42%), oba modele zgodnie zidentyfikowały trzy kluczowe stany atmosferyczne.
2. **Jakość grupowania:** Współczynniki sylwetki (Silhouette Score) wynoszące odpowiednio 0,375 dla k-średnich oraz 0,354 dla metody Warda świadczą o poprawnej i stabilnej strukturze klastrów. Dodatkowo miara redukcji wariancji R^2 osiągnęła wartości 67,63% dla algorytmu k-średnich oraz 64,73% dla metody Warda, co potwierdza dobrą zdolność obu metod do wyjaśniania zmienności danych.

3. **Wnioski merytoryczne:** Analiza potwierdziła silną korelację między stężeniem tlenków azotu (NO_x) a tlenkiem węgla (CO), co jest charakterystyczne dla zanieczyszczeń pochodzenia komunikacyjnego. Wyodrębnione skupienie „wysokiej emisji” wyraźnie odcina się od pozostałych, co może stanowić podstawę do projektowania systemów ostrzegania przed smogiem.
4. **Odniesienie do literatury:** Wyniki te są spójne z wnioskami zawartymi w pracy **De Vito i in. (2008)**, gdzie autorzy wskazywali na wysoką skuteczność czujników chemicznych w monitorowaniu trendów miejskich. Nasze badanie dowodzi, że proste metody uczenia nienadzorowanego, takie jak analiza skupień, są wystarczające do interpretacji złożonych sygnałów z sensorów i mogą być z powodzeniem stosowane w monitoringu środowiskowym.

Bibliografia

1. UCI Machine Learning Repository: Air Quality Data Set.
2. De Vito, S., et al. (2008). On-field calibration of an electronic nose for benzene estimation in an urban pollution monitoring station. *Sensors and Actuators B: Chemical*.
3. MacQueen, J. (1967). *Some methods for classification and analysis of multivariate observations*.
4. Ward, J. H. (1963). *Hierarchical Grouping to Optimize an Objective Function*.