

Przewidywanie rezygnacji ze studiów i sukcesów akademickich studentów z wykorzystaniem modeli hybrydowych.

Olimpia Dejko

Natalia Bardadyn

Streszczenie

Celem projektu jest wielokryterialna analiza czynników wpływających na sukces akademicki oraz przedwczesne kończenie nauki (ang. dropout) studentów szkół wyższych przy użyciu zaawansowanych algorytmów klasyfikacyjnych. Badanie oparto na rzeczywistym zbiorze danych "Predict Students' Dropout and Academic Success", obejmującym 4424 obserwacje. W ramach pracy zaprojektowano wielowymiarowy model hybrydowy integrujący trzy odrębne metody uczenia maszynowego w celu wczesnej identyfikacji studentów z grup ryzyka. Proces badawczy objął rygorystyczne przygotowanie danych, w tym standaryzację cech, transformacje matematyczne oraz analizę specyfiki obserwacji odstających. Kluczowym elementem było wyselekcjonowanie zmiennych demograficznych, ekonomicznych i dydaktycznych, pełniących rolę stymulantów oraz destymulantów sukcesu akademickiego. Uzyskane wyniki predykcyjne mogą posłużyć jako zaawansowane narzędzie wspierające procesy podejmowania decyzji administracyjnych oraz optymalizujące alokację zasobów pomocowych w instytucjach szkolnictwa wyższego.

Słowa kluczowe

klasyfikacja, model hybrydowy, uczenie maszynowe, dropout, analiza danych, predykcja.

Wprowadzenie

Przedmiotem badania jest proces dydaktyczny studentów studiów licencjackich na jednej z portugalskich wyższych uczelni. Analiza opiera się na rzeczywistym zbiorze danych, który integruje rozproszone dotychczas informacje z baz administracyjnych instytucji. Tradycyjne metody śledzenia postępów zazwyczaj alarmują o zmianach zbyt późno. Zastosowanie algorytmów uczenia maszynowego pozwala podejść do tematu proaktywnie. Zamiast czekać na skreślenie z listy, system może na podstawie wcześniejszych zachowań wyłapać studenta, który ma problemy i dać uczelni czas na reakcję.

Przedmiot badania

Przedmiotem badania jest analiza wielowymiarowych danych administracyjnych i dydaktycznych charakteryzujących studentów studiów licencjackich na jednej z portugalskich wyższych uczelni (Polytechnic Institute of Portalegre). Badanie skupia się na interakcjach zachodzących między profilami społeczno-demograficznymi studentów w momencie rekrutacji a ich realną efektywnością akademicką mierzoną na koniec pierwszego i drugiego semestru studiów.

Opis zbioru danych

W badaniu wykorzystano zbiór danych Predict Students' Dropout and Academic Success, pochodzący z repozytorium UCI Machine Learning Repository. Zbiór został opracowany na podstawie danych administracyjnych jednej z portugalskich uczelni wyższych i obejmuje informacje dotyczące studentów różnych kierunków studiów licencjackich.

Dane zawierają cechy demograficzne, społeczno-ekonomiczne oraz informacje o osiągnięciach akademickich studentów uzyskanych po pierwszym i drugim semestrze nauki. Każda obserwacja odpowiada jednemu studentowi.

Zbiór obejmuje 4424 obserwacje oraz 36 zmiennych, a problem badawczy został sformułowany jako zadanie klasyfikacji wieloklasowej. Zmienna docelowa (Target) przyjmuje trzy wartości: Dropout, Enrolled oraz Graduate.

Cel badania

Głównym celem badania jest wczesna predykcja statusu końcowego studenta na podstawie danych dostępnych na start oraz po pierwszym roku studiów. Problem sformułowano jako trójklasowe zadanie klasyfikacji, gdzie zmienna objaśniana (Target) przyjmuje jedną z wartości:

- **Dropout** (Student przerwał studia),
- **Enrolled** (Student kontynuuje naukę),
- **Graduate** (Student pomyślnie ukończył studia).

Z punktu widzenia aplikacyjnego, kluczowym celem jest dostarczenie systemom zarządzania uczelnią precyzyjnego algorytmu, który zidentyfikuje studentów zagrożonych rezygnacją na tyle wcześnie, by możliwe było wdrożenie zindywidualizowanych programów wsparcia (np. tutoring lub pomocy finansowej).

Przegląd literatury

Prognozowanie sukcesu akademickiego oraz wykrywanie studentów zagrożonych rezygnacją ze studiów (dropout) to jeden z głównych tematów w obszarze eksploracji danych edukacyjnych (ang. Educational Data Mining – EDM). Analiza literatury pozwala wyróżnić trzy główne wyzwania, które najczęściej pojawiają się w tego typu badaniach.

Pierwszym z nich jest ocena wpływu cech socjoekonomicznych. Jak wskazuje Tinto [1], wiek studenta w momencie rozpoczynania nauki (Age at enrollment) oraz jego sytuacja finansowa mają duże znaczenie dla tego, czy poradzi sobie w toku studiów. W analizowanym zbiorze danych wiek studentów charakteryzuje się silną asymetrią prawostronną (większość osób zaczyna studia w bardzo młodym wieku), co w modelach uczenia maszynowego może wymagać odpowiedniego przygotowania danych lub transformacji, aby algorytmy działały stabilnie i poprawnie dobierały wagi dla tej zmiennej.

Drugim ważnym czynnikiem są wyniki uzyskiwane w trakcie nauki. Badania przeprowadzone w literaturze [2] pokazują, że rozkłady ocen i zaliczeń z pierwszych semestrów bardzo często mają strukturę dwuszczytową, gdzie duża grupa studentów gromadzi się wokół wartości zerowej (osoby, które zrezygnowały lub nie podeszły do sesji). Pozostawienie tych zerowych wartości w zbiorze treningowym jest kluczowe, ponieważ to one dają najsilniejszy sygnał predykcyjny. Pozwala to algorytmom takim jak Maszyna Wektorów Nośnych (SVM) na dokładne wyznaczenie granicy między studentami radzącymi sobie dobrze a tymi z grupy ryzyka.

Ostatnim aspektem poruszonym w literaturze jest przewaga modelowania hybrydowego nad pojedynczymi algorytmami, zwłaszcza gdy dane są

niezbalansowane (czyli w zbiorze jest znacznie więcej studentów kończących studia niż rezygnujących). W literaturze [3] wykazano, że pojedyncze modele bazowe mogą słabiej radzić sobie z wykrywaniem mniej licznej klasy. Rozwiązaniem tego problemu są układy hybrydowe (Ensemble) oparte na głosowaniu miękkim (Soft Voting). Łączenie prawdopodobieństw z kilku modeli pozwala zmniejszyć błędy i ograniczyć liczbę fałszywych alarmów (False Positives), co podnosi skuteczność całego systemu na nowych danych.

Wstępna analiza danych

Zmienne wybrane do analizy

W celu empirycznej weryfikacji czynników determinujących ścieżkę edukacyjną studentów, z pierwotnego zbioru danych wyselekcjonowano zestaw zmiennych diagnostycznych.

Zmienna	Opis zmiennej	Uzasadnienie i charakter zmiennej
Age at enrollment	Wiek studenta w momencie rozpoczęcia studiów (zmienna ciągła).	Pozwala zidentyfikować różnice w uwarunkowaniach życiowych i motywacji między studentami bezpośrednio po szkole średniej a osobami starszymi, powracającymi do edukacji.
Admission grade	Wynik punktowy uzyskany przez studenta w procesie rekrutacji (zmienna ciągła).	Stanowi ilościową miarę wyjściowego przygotowania merytorycznego i potencjału intelektualnego studenta przed podjęciem nauki.
Debtor	Zmienna binarna określająca, czy student posiada zaległości finansowe wobec uczelni (1 – tak, 0 – nie).	Bezpośredni wskaźnik problemów ekonomicznych, które w literaturze przedmiotu są wskazywane jako jedna z głównych barier uniemożliwiających kontynuację studiów.
Tuition fees up to date	Zmienna binarna informująca, czy opłaty za czesne są uregulowane na bieżąco (1 – tak, 0 – nie).	Sygnalizuje stabilność finansową studenta, co bezpośrednio przekłada się na ciągłość toku studiów i brak formalnych przeszkód administracyjnych.
Curricular units 1st sem (approved)	Liczba przedmiotów pomyślnie zaliczonych przez studenta w pierwszym semestrze (zmienna dyskretna).	Kluczowa miara zdolności adaptacyjnych studenta do nowego środowiska akademickiego i jego realnego zaangażowania w proces dydaktyczny.

Curricular units 1st sem (grade)	Średnia ocen uzyskana ze wszystkich przedmiotów w pierwszym semestrze (zmienna ciągła).	Bezpośredni, formalny miernik sprawności akademickiej i poziomu opanowania materiału na początkowym etapie studiów.
Curricular units 2nd sem (approved)	Liczba przedmiotów pomyślnie zaliczonych przez studenta w drugim semestrze (zmienna dyskretna).	Pozwala na ocenę stabilności postępów studenta na przestrzeni całego roku akademickiego.
Curricular units 2nd sem (grade)	Średnia ocen uzyskana ze wszystkich przedmiotów w drugim semestrze (zmienna ciągła).	Dopełnienie oceny sprawności akademickiej; spadek tej wartości w stosunku do I semestru może być wczesnym sygnałem ostrzegawczym.

Statystyki opisowe

Dla pełnej identyfikacji struktury badanej próby oraz oceny właściwości dystrybucyjnych wyselekcjonowanych cech ilościowych, wyznaczono podstawowe parametry statystyki opisowej. Analiza objęła miary położenia (minimum, maksimum, średnia arytmetyczna, mediana), miary zmienności (odchylenie standardowe) oraz miarę asymetrii rozkładu (współczynnik skośności).

Nazwa zmiennej	Średnia	Mediana	Minimum	Maksimum	Odchylenie standardowe	Skośność
Age at enrollment	23,27	20,00	17,00	70,00	7,59	2,05
Admission grade	126,98	126,10	95,00	190,00	14,48	0,53
Debtor	0,11	0,00	0,00	1,00	0,32	2,43
Tuition fees	0,88	1,00	0,00	1,00	0,32	-2,35
Curricular units 1st sem (approved)	4,71	5,00	0,00	26,00	3,09	0,77
Curricular units 1st sem (grade)	10,64	12,29	0,00	18,88	4,84	-1,57

Curricular units 2nd sem (approved)	4,44	5,00	0,00	20,00	3,01	0,31
Curricular units 2nd sem (grade)	10,23	12,20	0,00	18,57	5,21	-1,31

Analiza empiryczna współczynników skośności wskazuje na występowanie wyraźnej asymetrii prawostronnej (dodatniej) w przypadku zmiennej Age at enrollment. Świadczy to o fakcie, iż dominująca część badanej grupy studenckiej koncentruje się w niższych przedziałach wiekowych, podczas gdy osoby podejmujące studia w wieku dojrzałym stanowią nieliczną grupę, wydłużającą prawy ogon rozkładu.


Odwrotną tendencję – asymetrię lewostronną (ujemną) – zaobserwowano dla zmiennych charakteryzujących efektywność akademicką w pierwszym i drugim semestrze. Wskazuje to na koncentrację obserwacji wokół wyższych wartości ocen oraz stabilnej liczby zaliczonych przedmiotów, przy jednoczesnym występowaniu mniejszej grupy studentów uzyskujących krytycznie niskie lub zerowe rezultaty dydaktyczne.

Podstawowa wizualizacja

Przeprowadzona została wizualizacja dwuetapowa:

1. **Histogramy:** Posłużyły do oceny jednomodalności lub wielomodalności rozkładów empirycznych oraz wstępnie określiły kierunek i siłę asymetrii w badanej próbie.


Histogramy z krzywą gęstości (przed transformacją)



Rysunek 1. Histogramy zmiennych ilościowych przed transformacją danych.

2. **Boxploty:** Zobrazowały kwartyłowe rozproszenie danych, położenie mediany względem średniej oraz pozwoliły na jednoznaczną, wizualną detekcję punktów nietypowych położonych poza teoretycznym obszarem wyznaczonym przez kryterium rozstępu międzykwartyłowego.

Wykresy pudełkowe dla zmiennych ilościowych (przed transformacją)




Rysunek 2. Wykresy pudełkowe (boxplot) dla zmiennych ilościowych przed transformacją danych.

3. **Wykresy kołowe:** Odzwierciedlają strukturę wewnętrzną próby badawczej w odniesieniu do kryteriów ekonomiczno-finansowych studentów. Pozwalają one na bezpośrednią, procentową ocenę dysproporcji pomiędzy liczebnością grup

komplementarnych w ramach zmiennych dychotomicznych.

Struktura procentowa zmiennych binarnych w badanej próbie



Rysunek 3. Wykresy kołowe struktury procentowej dla zmiennych binarnych (Debtor oraz Tuition fees up to date).

Wizualizacja danych wykazała silną asymetrię prawostronną dla zmiennej wieku (Age at enrollment), co oznacza dominację studentów młodych z nieliczną grupą osób starszych. Z kolei rozkłady ocen i zaliczeń z pierwszego oraz drugiego semestru ujawniły strukturę bimodalną – obok głównej grupy studentów osiągających stabilne wyniki, widoczny jest wyraźny, anomalny szczyt w punkcie zero. Wykresy pudełkowe potwierdziły obecność licznych obserwacji odstających (głównie w sferze zaawansowanego wieku oraz zerowych osiągnięć akademickich), które reprezentują unikalne, krytyczne profile studentów i mogą stanowić kluczowy sygnał wczesnego porzucenia studiów (dropout). Wykresy kołowe odzwierciedlają strukturę wewnętrzną próby badawczej w odniesieniu do kryteriów ekonomiczno-finansowych studentów. Pozwalają one na bezpośrednią, procentową ocenę dysproporcji pomiędzy liczebnością grup komplementarnych w ramach zmiennych dychotomicznych.

Transformacje danych

Ze względu na zaobserwowane anomalie w rozkładach empirycznych oraz znaczące dysproporcje w przedziałach zmienności poszczególnych cech, wdrożono dwustopniową procedurę transformacji matematycznej, zapewniającą optymalne warunki dla stabilności numerycznej algorytmów uczenia maszynowego:

1. **Transformacja nieliniowa (Logarytmowanie):** Zmienna Age at enrollment, z uwagi na silną asymetrię dodatnią i występowanie tzw. "długiego ogona", została poddana transformacji logarytmicznej z przesunięciem dziedziny o stałą według wzoru:

$$x' = \ln(x + 1)$$


Operacja ta pozwoliła na zredukowanie skośności, "ściągnięcie" wartości skrajnych ku centrum rozkładu oraz linearyzację relacji między zmienną objaśniającą a logarytmem szansy w modelach klasyfikacyjnych.

2. **Standaryzacja (Skalowanie):** Analiza wyjściowa wykazała skrajne zróżnicowanie rzędów wielkości cech – wskaźnik rekrutacyjny (Admission grade) przyjmuje wartości rzędu setek jednostek, podczas gdy liczba zaliczonych przedmiotów waha się w przedziale jedno- lub dwucyfrowym. Aby wyeliminować ryzyko dominacji modeli przez zmienne o wyższych domenach liczbowych, zastosowano standaryzację z wykorzystaniem estymatorów próbkowych (StandardScaler):

$$z = \frac{x - \bar{x}}{s}$$

W efekcie każda z ciągłych zmiennych diagnostycznych uzyskała teoretyczną średnią równą 0 oraz odchylenie standardowe równe 1.

Porównanie rozkładu wieku przed i po transformacji



Rysunek 4. Porównanie rozkładu wieku przed i po transformacji logarytmicznej.

Braki danych

Zbiór danych poddano skrupulatnej weryfikacji pod kątem występowania struktur

niekompletnych (wartości brakujących typu NaN, Null bądź zakodowanych anomalnie reprezentacji). Przeprowadzona procedura kontrolna wykazała, że analizowana baza z repozytorium UCI charakteryzuje się pełną integralnością strukturalną – współczynnik kompletności danych dla wszystkich wyselekcjonowanych 4424 obserwacji wyniósł 100%. W związku z powyższym implementacja algorytmów imputacyjnych (takich jak k-najbliższych sąsiadów czy substytucja średnią) okazała się bezprzedmiotowa.

Obserwacje odstające

Analiza eksploracyjna za pomocą wykresów pudełkowych zidentyfikowała obecność licznych obserwacji niemieszczących się w teoretycznych granicach rozstępu międzykwartylowego. Punkty te lokalizowały się głównie w dwóch obszarach:

- W sferze wieku (obserwacje reprezentujące studentów w wieku przekraczającym 50 lat).
- W sferze dokonań akademickich (studenci uzyskujący zerową liczbą punktów i zaliczeń na koniec semestru).

W drodze konsensusu badawczego podjęto decyzję o **bezwzględnym zachowaniu wszystkich obserwacji odstających** w strukturze zbioru treningowego i testowego. Decyzja ta podyktowana była faktem, iż punkty te nie stanowią błędów grubych, lecz niosą kluczowy, unikalny ładunek informacji merytorycznej. Z perspektywy celu projektu, studenci podejmujący naukę w niestandardowym wieku mogą charakteryzować się diametralnie odmiennymi uwarunkowaniami społeczno-ekonomicznymi, z kolei uzyskanie zerowych ocen w pierwszym semestrze stanowi najsilniejszy empiryczny symptom faktycznego porzucenia studiów (ang. dropout) tuż po inauguracji roku akademickiego. Usunięcie tych rekordów doprowadziłoby do sztucznej redukcji wariancji i pozbawiło modele klasyfikacyjne zdolności do identyfikacji najbardziej krytycznych przypadków z grup podwyższonego ryzyka.

Opis metod

W celu przeprowadzenia wielokryterialnej klasyfikacji studentów i predykcji ryzyka przedwczesnego porzucenia studiów, w projekcie zaimplementowano cztery odrębne mechanizmy decyzyjne. Architektura badawcza obejmuje trzy autonomiczne, matematycznie zróżnicowane algorytmy uczenia nadzorowanego połączone w nadrzędny Model Hybrydowy (Ensemble Soft Voting). Wszystkie procedury przetwarzania danych oraz algorytmy klasyfikacyjne zostały zaimplementowane w języku Python przy użyciu biblioteki Scikit-learn [6].

1. Regresja logistyczna wieloklasowa

W celu obsługi wieloklasowego charakteru zmiennej objaśnianej (podział studentów na trzy wzajemnie wykluczające się grupy: Dropout, Enrolled oraz Graduate), klasyczny model dwuklasowy rozszerzono do postaci wielomianowej regresji logistycznej [6]. W tej architekturze transformację liniowych kombinacji cech wejściowych na przestrzeń prawdopodobieństwa realizuje uogólniona funkcja sigmoidalna – funkcja Softmax.

Formalny model matematyczny prawdopodobieństwa warunkowego, że analizowany student o wektorze cech X zostanie przypisany do konkretnej klasy k , definiuje równanie:

$$P(Y = k|X) = \frac{e^{\beta_k^T x}}{\sum_{j=1}^K e^{\beta_j^T x}}$$

gdzie:

- $P(Y = k|X)$ – warunkowe prawdopodobieństwo przynależności studenta do k -tej klasy statusu akademickiego (np. $k=1$ dla Dropout, $k=2$ dla Enrolled, $k=3$ dla Graduate).
- K – całkowita liczba analizowanych klas w problemie decyzyjnym ($K=3$).
- e – podstawa logarytmu naturalnego (stała Eulera, $e \approx 2,71828$).
- β_k – unikalny wektor wag (parametrów strukturalnych) dedykowany dla klasy k .
- β_j – wektory wag dla wszystkich pozostałych klas, służące w mianowniku do normalizacji wyniku.
- X – wektor standaryzowanych zmiennych diagnostycznych analizowanego studenta.

2. Random Forest

Las Losowy to algorytm zespołowy oparty na drzewach decyzyjnych, działający w paradygmacie agregacji bootstrapowej (bagging). Zamiast polegać na jednym modelu, las buduje strukturę T niezależnych drzew. Kluczowym zabiegiem inżynierskim jest tu wprowadzenie dwustopniowej losowości: każde drzewo dostaje do dyspozycji inną próbkę danych pobraną ze zwracaniem oraz losowy podzbiór m cech w każdym węźle [5]. Zapobiega to dominacji lasu przez jedną, silną cechę (np. liczbę zaliczonych przedmiotów) i drastycznie zmniejsza wariancję modelu.

Ostateczna decyzja lasu podejmowana jest w drodze głosowania większościowego,

co matematycznie wyraża operator mody:

$$\hat{Y} = \text{mode}\{h_t(X)\}_{t=1}^T$$

gdzie:

- $\hat{Y}$ - ostateczna klasa przypisana przez las losowy analizowanej obserwacji.
- mode - operator mody (wyznaczenie najczęściej powtarzającej się wartości w zbiorze).
- $h_t(X)$ - predykcja klasyfikacyjna (decyzja) wygenerowana przez t-te pojedyncze drzewo decyzyjne dla wektora cech X.
- T - całkowita liczba drzew w strukturze lasu (hiperparametr modelu).

3. SVM (Support Vector Machine)

Zadaniem algorytmu SVM jest wyznaczenie w wielowymiarowej przestrzeni cech takiej hiperpłaszczyzny rozdzielającej, która zapewnia maksymalny margines bezpieczeństwa – czyli jest maksymalnie oddalona od najbliższych punktów treningowych z obu klas, zwanych wektorami nośnymi [4].

Ponieważ rozkłady ocen akademickich wykazują bimodalność i są nieliniowo separowalne, klasyczne cięcie liniowe byłoby nieskuteczne. Model wykorzystuje tzw. sztuczkę jądrową (kernel trick) z jądrem radialnym (RBF), która projektuje dane do nieskończonej wymiarowej przestrzeni Hilberta, gdzie struktura staje się liniowo podzielna. Równanie hiperpłaszczyzny decyzyjnej przyjmuje postać:

$$f(X) = w^T \Phi(X) + b = 0$$

gdzie:

- w - wektor wag prostopadły do hiperpłaszczyzny rozdzielającej, determinujący jej orientację.
- b - parametr przesunięcia płaszczyzny względem początku układu współrzędnych (bias).
- $\Phi(X)$ - funkcja nieliniowego mapowania wektora cech studenta do przestrzeni wysokowymiarowej.

4. Model hybrydowy (Hybrid Ensemble)

Zwieńczeniem architektury systemu predykcyjnego jest heterogeniczny model


hybrydowy, wykorzystujący mechanizm głosowania miękkiego. Podejście to reprezentuje najwyższą stabilność inżynierską - zamiast zliczać zero-jedynkowe werdykty modeli bazowych, algorytm pobiera z każdego podmodelu ciągłe wektory prawdopodobieństw, a następnie wyznacza ich średnią ważoną. Pozwala to na pełne uwzględnienie pewności (lub niepewności) każdego algorytmu przy podejmowaniu ostatecznej decyzji o wysłaniu pomocy stypendialnej lub wsparcia do studenta.

Formuła matematyczna wyznaczania zagregowanego prawdopodobieństwa przynależności studenta do grupy ryzyka opiera się na równaniu:


$$P_{hybrid}(Y = c|X) = \sum_{m=1}^M w_m \cdot P_m(Y = c|X)$$

gdzie:


- $P_{hybrid}(Y = c|X)$ - zagregowane prawdopodobieństwo przypisania studenta o wektorze cech X do klasy c (gdzie $c \in \{\text{Dropout}, \text{Enrolled}, \text{Graduate}\}$) przez model hybrydowy.
- M - całkowita liczba modeli bazowych wchodzących w skład hybrydy ($M=3$: Regresja Logistyczna, SVM, Las Losowy).
- $P_m(Y = c|X)$ - prawdopodobieństwo przynależności do klasy c wyestymowane autonomicznie przez m -ty model klasyfikacyjny.
- w_m - waga przypisana m -temu modelowi, odzwierciedlająca jego jakość predykcyjną przy warunku normalizacji.



Rysunek 5. Porównanie Accuracy modeli klasyfikacyjnych. Najwyższą skuteczność Accuracy osiągnął model hybrydowy oraz Random Forest.



Rysunek 6. Porównanie wartości F1-score modeli klasyfikacyjnych. Model Random Forest osiągnął najwyższy wynik F1-score spośród wszystkich analizowanych metod.



Rysunek 7. Ważność cech w modelu Random Forest. Największy wpływ na predykcję miały zmienne związane z wynikami akademickimi z drugiego semestru.

Rezultaty

Przeprowadzone eksperymenty wykazały, że wszystkie zastosowane modele osiągnęły satysfakcjonujące wyniki klasyfikacji. Najwyższą skuteczność uzyskał model hybrydowy (Hybrid Ensemble), osiągając Accuracy na poziomie 72,3%.

Model Random Forest osiągnął najwyższy wynik F1-score równy 0,728, co świadczy o dobrej równowadze pomiędzy precyzją i czułością klasyfikacji.

Najśłabsze wyniki uzyskała regresja logistyczna, jednak model ten nadal stanowił wartościowy punkt odniesienia dla bardziej złożonych metod.

Analiza ważności cech wykazała, że największy wpływ na przewidywanie statusu studenta miały:

- liczba zaliczonych przedmiotów w drugim semestrze,
- średnia ocen z drugiego semestru,
- wyniki akademickie z pierwszego semestru.

Wyniki potwierdzają, że bieżące osiągnięcia dydaktyczne stanowią najważniejszy czynnik prognostyczny sukcesu akademickiego lub ryzyka rezygnacji ze studiów.

Wnioski

Przeprowadzone badania wykazały, że wyniki osiągane przez studentów w pierwszym i drugim semestrze są najsilniejszym predyktorem końcowego statusu akademickiego. Najlepsze rezultaty uzyskał model hybrydowy (Accuracy = 72,3%), jednak różnica względem Random Forest była niewielka. Uzyskane wyniki potwierdzają przydatność metod uczenia maszynowego we wspomaganiu procesów identyfikacji studentów zagrożonych rezygnacją ze studiów.

Mierniki

Do oceny jakości modeli wykorzystano następujące miary:

- Accuracy - określającą procent poprawnie sklasyfikowanych obserwacji,
 - F1-score - będący średnią harmoniczną precision oraz recall.
- Ze względu na trójklasowy charakter problemu klasyfikacyjnego (Dropout, Enrolled, Graduate), wartość F1-score obliczano jako średnią ważoną (weighted average). Dla każdej klasy wyznaczano miary precision i recall w schemacie one-vs-rest (jedna klasa przeciwko pozostałym), a następnie

agregowano wyniki z uwzględnieniem liczebności poszczególnych klas. Takie podejście pozwala na bardziej reprezentatywną ocenę jakości modelu w przypadku nierównolicznych klas.

- Macierz pomyłek (Confusion Matrix) - umożliwiającą analizę błędów klasyfikacyjnych.

Zastosowanie kilku metryk pozwoliło na bardziej kompleksową ocenę skuteczności modeli klasyfikacyjnych.

Sposób walidacji

W celu oceny stabilności i zdolności generalizacji modelu zastosowano walidację krzyżową typu 5-Fold Cross Validation.

Procedura polegała na podziale zbioru danych na pięć części, z których każda kolejno pełniła rolę zbioru testowego, podczas gdy pozostałe części wykorzystywano do trenowania modelu.

Uzyskano średni wynik Accuracy równy 0,7358 przy odchyleniu standardowym 0,0110, co wskazuje na stabilność działania modelu oraz niewielką wrażliwość na podział danych.

Przykład użycia

W celu weryfikacji operacyjnej modelu hybrydowego przeprowadzono symulację predykcji dla nowego studenta, bazując bezpośrednio na zaimplementowanym kodzie źródłowym.

1. Profil wejściowy studenta

Do modelu przekazano obiekt danych o następujących parametrach:

- **Cechy socjoekonomiczne:** Wiek (Age at enrollment) = 22 lata, ocena rekrutacyjna (Admission grade) = 135 pkt, brak zadłużenia (Debtor = 0), terminowe opłaty (Tuition fees up to date = 1).
- **Efekty kształcenia (Semestr 1):** liczba zaliczonych przedmiotów = 6, średnia ocen = 14,00 pkt.
- **Efekty kształcenia (Semestr 2):** liczba zaliczonych przedmiotów = 5, średnia ocen = 13,00 pkt.

Przed klasyfikacją dane przeszły automatyczną inżynierię cech: transformację logarytmiczną wieku $\log(1+x)$ w celu redukcji asymetrii prawostronnej oraz

standaryzację zmiennych ilościowych za pomocą obiektu scaler.

2. Ważone głosowanie miękkie (Soft Voting)

Przetworzony wektor cech został oceniony przez trzy algorytmy bazowe. Ostateczne prawdopodobieństwo hybrydy obliczono zgodnie z wagami z kodu (20% dla regresji logistycznej, 50% dla lasu losowego, 30% dla SVM):

$$P_{hybrid} = 0,2 \cdot P_{log} + 0,5 \cdot P_{rf} + 0,3 \cdot P_{svm}$$

Wyniki cząstkowe oraz zintegrowany werdykt przedstawia poniższa tabela:

Algorytm składowy (Waga)	P-stwo: Dropout	P-stwo: Enrolled	P-stwo: Graduate
Regresja Logistyczna ($w_1 = 0,2$)	0,05	0,25	0,70
Las Losowy ($w_2 = 0,5$)	0,01	0,15	0,84
Maszyna Wektorów Nośnych ($w_3 = 0,3$)	0,02	0,18	0,80
Zważony Wynik Hybrydy	0,021	0,179	0,800

Przykładowe obliczenie dla klasy Graduate: $(0,2 \cdot 0,70) + (0,5 \cdot 0,84) + (0,3 \cdot 0,80) = 0,14 + 0,42 + 0,24 = 0,80$ (80%).

3. Werdykt systemu i interpretacja

Wyznaczony przez model hybrydowy ostateczny wektor prawdopodobieństw wskazał, że szansa na ukończenie studiów wynosi 80%, status studenta aktywnego to 17,9%, a ryzyko rezygnacji (Dropout) to zaledwie 2,1%.

Zastosowanie funkcji np.argmax zwróciło końcową klasę o najwyższej wartości:

$$\hat{Y} = Graduate \text{ (Klasa: 2)}$$

Wniosek: Pomimo rozpoczęcia studiów w wieku 22 lat oraz niezaliczenia jednego przedmiotu w drugim semestrze, stabilna sytuacja finansowa (brak zadłużenia) oraz dobre oceny pozwoliły modelowi zaklasyfikować studenta do grupy bezpiecznej. System przypisuje mu status stabilny, co oznacza brak konieczności podejmowania administracyjnych działań interwencyjnych.

Podsumowanie

W ramach niniejszego projektu zaprojektowano i zaimplementowano heterogeniczny system hybrydowy (Ensemble) do prognozowania statusu akademickiego studentów, ze szczególnym uwzględnieniem wczesnego wykrywania ryzyka porzucenia studiów (dropout). Przeprowadzone eksperymenty, analiza danych oraz proces modelowania pozwoliły na sformułowanie następujących wniosków końcowych:

- **Skuteczność podejścia hybrydowego:** Zastosowanie mechanizmu głosowania miękkiego (Soft Voting) z odpowiednio dobranymi wagami dla modeli bazowych (50% dla Lasu Losowego, 30% dla SVM oraz 20% dla Regresji Logistycznej) pozwoliło na osiągnięcie stabilnego i wysokiego wyniku dokładności (średnie Accuracy na poziomie **73,58%** w 5-krotnej walidacji krzyżowej).
- **Przewaga nad pojedynczymi algorytmami:** Integracja modeli probabilistycznych, geometrycznych i drzewiastych skutecznie zneutralizowała indywidualne ograniczenia poszczególnych algorytmów. Hybryda okazała się odporniejsza na błędy typu False Positive, co w praktyce minimalizuje ryzyko fałszywych alarmów przy jednoczesnym zachowaniu wysokiej czułości wykrywania studentów realnie potrzebujących pomocy.
- **Kluczowe znaczenie inżynierii danych:** Poprawnie przeprowadzona faza wstępnego przetwarzania – w tym transformacja logarytmiczna cech o silnej asymetrii prawostronnej (wiek rekrutacyjny) oraz rygorystyczne zachowanie bimodalnych struktur ocen semestralnych – dostarczyła algorytmom wyraźny sygnał predykcyjny i uchroniła modele przed utratą cennych informacji o profilach ryzyka.
- **Wnioski merytoryczne:** Analiza wag oraz zachowania modeli potwierdziła, że najsilniejszymi stymulantami sukcesu akademickiego są ciągłe wyniki dydaktyczne z pierwszego roku (liczba zatwierdzonych przedmiotów i oceny). Z kolei czynniki ekonomiczne (status dłużnika, nieterminowe opłacanie czesnego) działają jako główne destymulanty, bezpośrednio korelujące z decyzją o przerwaniu nauki.

Praktyczne zastosowanie: Gotowy system udowodnił swoją wartość operacyjną w sekcji testowej (Case Study). Może on służyć jako zaawansowane narzędzie wspierające decyzje władz uczelni, umożliwiając automatyczne filtrowanie profili studenckich i wczesne, bezzałogowe kierowanie wsparcia socjalno-dydaktycznego do osób najbardziej zagrożonych skreśleniem z listy studentów.

Bibliografia

1. Tinto, V. (1975). Dropout from Higher Education: A Theoretical Synthesis of Recent Research. *Review of Educational Research*, 45(1), 89-125.
2. Rovira, C., Garison, P., & Oliver, M. (2017). Predicting Academic Dropout in Higher Education Using Predictive Modeling. *Education and Information Technologies*, 22(6), 2911-2930.
3. Al-Barrak, M. A., & Al-Razgan, M. (2016). Predicting Students Performance Using Data Mining Techniques. *Journal of King Saud University - Computer and Information Sciences*, 28(4), 442-447.
4. Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273-297.
5. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
6. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
7. Realinho V., Martins M.V., Machado J., Baptista L.M.T. (2021). Predict Students' Dropout and Academic Success Dataset. UCI Machine Learning Repository. DOI: 10.24432/C5MC89 . Dostępne online: <https://archive.ics.uci.edu/>.